

Relatório — Projeto Final de Banco de Dados

Disciplina: Banco de Dados — DCC/UFMG

Professor: Pedro H. Barros

Dataset: Oscar AMPAS — Winner Demographics (1927–2014)

1. Introdução

Este projeto implementa o ciclo completo de um banco de dados relacional sobre os vencedores do Oscar (Academy Awards), premiação anual da Academia de Artes e Ciências Cinematográficas dos Estados Unidos (AMPAS). O dataset contém informações demográficas de vencedores de cinco categorias principais entre 1927 e 2014, permitindo análises sobre representatividade étnica, longevidade de carreira e domínio artístico ao longo de quase nove décadas de cinema.

As etapas de um projeto de banco de dados desenvolvidas partem do projeto conceitual Entidade-Relacionamento, que é depois convertido num modelo Relacional e testado sobre as premissas das 3 formas normais. Os modelos projetados são então implementados em SQL por meio da Data Definition language (DDL) e a base de dados resultante é populada com o arquivo csv. Antes de se executar as análises e consultas SQL, um tratamento é feito, seguido da análise exploratória dos dados.

Motivação

O Oscar é a premiação cinematográfica mais influente do mundo. Analisar o perfil dos vencedores ao longo do tempo revela padrões históricos de diversidade — ou ausência dela — na indústria do cinema.

2. Dataset

Atributo	Valor
Fonte	FiveThirtyEight / AMPAS
Arquivo	world_ampas_oscar_winner_demographics.csv
Linhas	415
Colunas	10
Período	1927 a 2014

Colunas originais

Coluna	Tipo	Descrição
name	texto	Nome do vencedor
birth_year	inteiro	Ano de nascimento
birth_date	data	Data de nascimento
birthplace	texto	Local de nascimento (texto livre)
race_ethnicity	texto	Etnia (6 valores: White, Black, Hispanic, Asian, Multiracial, Middle Eastern)
religion	texto	Religião — 62% ausente
sexual_orientation	texto	Orientação sexual — “Na” tratado como NULL
year_edition	inteiro	Ano da cerimônia
category	texto	Categoria do Oscar (5 categorias)
movie	texto	Filme premiado

Coluna	Tipo	Descrição
--------	------	-----------

Tratamento de dados ausentes

- **religion**: 62% de ausência estrutural — dado não coletado para todos os vencedores históricos. Tratado como NULL.
- **sexual_orientation**: string "Na" convertida para NULL na carga.
- **birth_date**: 1 registro ausente; **birth_year** mantido para não perder informação.

3. Modelo Entidade-Relacionamento


Entidades

Entidade	Atributos	Chave
VENCEDOR	nome, ano_nascimento, data_nascimento, local_nascimento, etnia, religiao, orient_sexual	id_vencedor
FILME	titulo	id_filme
CATEGORIA	nome	id_categoria
EDICAO	ano	id_edicao
PREMIO	— (somente FKs)	id_premio

Relacionamentos

- PREMIO é uma **entidade associativa** que conecta as quatro dimensões.
- Todos os relacionamentos são **N:1** de PREMIO para as demais entidades.
- Um vencedor pode ter múltiplos prêmios (ex: Katharine Hepburn — 4 Oscars).
- Um filme pode vencer múltiplas categorias na mesma edição.

Diagrama ER



4. Modelo Relacional

vencedor(id_vencedor PK, nome, ano_nascimento, data_nascimento, local_nascimento, etnia, religiao, orient_sexual)

filme(id_filme PK, titulo)

categoria(id_categoria PK, nome)

edicao(id_edicao PK, ano)

premio(id_premio PK,
id_vencedor FK → vencedor,
id_filme FK → filme,
id_categoria FK → categoria,
id_edicao FK → edicao)

Normalização

1FN: todos os valores são atômicos. local_nascimento é texto livre, mas atômico por linha.

2FN: todas as tabelas têm chave primária simples — dependências parciais são impossíveis.

3FN: único caso analisado foi ano_nascimento vs data_nascimento em VENCEDOR. Optou-se por manter ambos pois há 1 registro com birth_year mas sem birth_date completa — eliminar a coluna causaria perda real de informação. Não há dependências transitivas nas demais tabelas.

5. Implementação Física

Banco de dados

- **SGBD:** PostgreSQL 16 (via Docker)
- **Container:** oscar-db
- **Banco:** oscar

Constraints implementadas

Constraint	Tipo	Tabela
id_* únicos e não nulos	Chave primária	Todas
nome NOT NULL	Entidade	vencedor, filme, categoria
ano >= 1927	Domínio	edicao
FKs referenciam registros existentes	Referencial	premio
(id_vencedor, id_categoria, id_edicao) único	Negócio	premio

Índices criados

```
CREATE INDEX idx_premio_vencedor ON premio(id_vencedor);
CREATE INDEX idx_premio_filme ON premio(id_filme);
CREATE INDEX idx_premio_categoria ON premio(id_categoria);
CREATE INDEX idx_premio_edicao ON premio(id_edicao);
```

6. Carga dos Dados

Pipeline em Python (Etapas3_SQL/02_carga_dados.py) usando psycopg2.

Ordem de inserção: 1. **edicao** — 87 cerimônias 2. **categoria** — 5 categorias 3. **filme** — 335 títulos únicos 4. **vencedor** — 348 pessoas únicas (deduplicadas por nome) 5. **premio** — 415 registros (um por linha do CSV)

Validação pós-carga: - Zero registros órfãos em todas as FKs - Nenhuma duplicata na constraint **uq_premio** - NULLs distribuídos como esperado (**religion**: 219, **orient_sexual**: 10)

7. Análise Exploratória

P1 — Filmes com múltiplas vitórias na mesma edição

It Happened One Night (1935), *Gone with the Wind* (1940) e *Going My Way* (1945) foram os únicos a vencer 3 categorias em uma mesma cerimônia. 60 filmes no total venceram 2 ou mais categorias.

P2 — Diversidade étnica por década

Até os anos 1970, a proporção de vencedores não-brancos foi praticamente zero. A partir dos anos 2000, subiu para cerca de 19%, ainda longe de representar a diversidade da população americana.

P3 — Idade dos vencedores

Atrizes vencem mais jovens (média 37 anos) enquanto atores coadjuvantes vencem mais velhos (média 51). A mais jovem foi Tatum O'Neal com 11 anos (1974); o mais velho foi Christopher Plummer com 83 anos (2012).

P4 — Intervalo entre vitórias

Helen Hayes esperou 39 anos entre seu primeiro (1932) e segundo Oscar (1971), o maior intervalo registrado. Katharine Hepburn também esperou 34 anos (1934–1968).

P5 — Primeira vitória não-branca por categoria

Categoria	Vencedor	Etnia	Ano
Best Supporting Actress	Hattie McDaniel	Black	1940
Best Actor	Jose Ferrer	Hispanic	1951
Best Supporting Actor	Anthony Quinn	Hispanic	1953
Best Actress	Halle Berry	Multiracial	2002
Best Director	Ang Lee	Asian	2006

8. Conclusão

O projeto implementou com sucesso todas as etapas do ciclo de vida de um banco de dados relacional: modelagem ER, mapeamento relacional, normalização até 3FN, implementação DDL com restrições de integridade, pipeline de carga e análise exploratória via SQL e visualizações.

Os dados revelam que a Academia de Artes e Ciências Cinematográficas demorou décadas para reconhecer artistas não-brancos, com a primeira vitória não-branca em Best Director ocorrendo apenas em 2006 — quase 80 anos após a primeira cerimônia.

Arquivos do Projeto