

Relatório — Projeto Final de Banco de Dados

Disciplina: Banco de Dados — DCC/UFMG

Professor: Pedro H. Barros

Dataset: Oscar AMPAS — Winner Demographics (1927–2014)

Grupo:

1. Lucas Samuel Fernandes Andrade Oliveira,
2. Felipe Ribas Muniz,
3. Iury Alves Bicalho e
4. Bruno dos Santos Lopes

1. Introdução

Este projeto implementa o ciclo completo de um banco de dados relacional sobre os vencedores do Oscar (Academy Awards), premiação anual da Academia de Artes e Ciências Cinematográficas dos Estados Unidos (AMPAS). O dataset contém informações demográficas de vencedores de cinco categorias principais entre 1927 e 2014, permitindo análises sobre representatividade étnica, longevidade de carreira e domínio artístico ao longo de quase nove décadas de cinema.

As etapas de um projeto de banco de dados desenvolvidas partem do projeto conceitual Entidade-Relacionamento, que é depois convertido num modelo Relacional e testado sobre as premissas das 3 formas normais. Os modelos projetados são então implementados em SQL por meio da Data Definition language (DDL) e a base de dados resultante é populada com o arquivo csv. Antes de se executar as análises e consultas SQL, um tratamento é feito, seguido da análise exploratória dos dados.

Motivação

O Oscar é a premiação cinematográfica mais influente do mundo. Analisar o perfil dos vencedores ao longo do tempo revela padrões históricos de diversidade na indústria do cinema.

2. Dataset

A base de dados utilizada, “World Oscar AMPAS winner demographics”, contém dados a respeito das categorias: Melhor Atriz, Melhor Ator, Melhor Diretor, Melhor Ator Coadjuvante, Melhor Atriz Coadjuvante, para as edições da premiação que ocorreram entre 1927 e 2014. Os atributos do dataset e a relação das variáveis presentes está mostrada na tabela a seguir:

Atributo	Valor
Fonte	FiveThirtyEight / AMPAS
Arquivo	world_ampas_oscar_winner_demographics.csv
Linhas	415
Colunas	10
Período	1927 a 2014

Colunas originais

Coluna	Tipo	Descrição
name	texto	Nome do vencedor
birth_year	inteiro	Ano de nascimento
birth_date	data	Data de nascimento
birthplace	texto	Local de nascimento (texto livre)
race_ethnicity	texto	Etnia (6 valores: White, Black, Hispanic, Asian, Multiracial, Middle Eastern)
religion	texto	Religião
sexual_orientation	texto	Orientação sexual
year_edition	inteiro	Ano da cerimônia
category	texto	Categoria do Oscar (5 categorias: Melhor Atriz, Melhor Ator, Melhor Diretor, Melhor Ator Coadjuvante, Melhor Atriz Coadjuvante)
movie	texto	Filme premiado

Tratamento de dados ausentes

Foram realizadas os seguintes tratamentos na base original importada:

- **religion**: Tratado como NULL para valores ausentes.
- **sexual_orientation**: string "Na" convertida para NULL na carga.
- **birth_date**: 1 registro ausente; **birth_year** mantido para não perder informação.

3. Etapa 1: Modelo Entidade-Relacionamento

Entidades

Entidade	Atributos	Chave
VENCEDOR	nome, ano_nascimento, data_nascimento, local_nascimento, etnia, religiao, orient_sexual	id_vencedor
FILME	titulo	id_filme
CATEGORIA	nome	id_categoria
EDICAO	ano	id_edicao
PREMIO	id_vencedor, id_filme, id_categoria, id_edicao	id_premio

Relacionamentos


O projeto para o banco de dados considerou a criação de **PREMIO**, que é uma **entidade associativa** que conecta as quatro demais entidades. **PREMIO** permite que **VENCEDOR**, **FILME**, **EDICAO** e **CATEGORIA**

se relacionem diretamente, de forma que caracterizem uma entrada na base de dados, ou seja, cada **PREMIO** corresponde a uma das categorias do Oscar em determinada edição, da qual houve um vencedor por causa de determinado filme.

Nessa estruturação, é obrigatório que cada uma dessas 4 entidades possuam uma respectiva entrada nas demais 3 que se associem a ela, caracterizando uma participação total. A entidade associativa caracteriza um relacionamento M:N.

Diagrama ER

O diagrama a seguir representa o esquemático da modelagem apresentada anteriormente, com as entidades, relacionamentos representados pela notação clássica.



Restrições de integridade de domínio

VENCEDOR

id_vencedor (Chave): - Tipo: Numérico Inteiro (ex: INT). - Restrição: Único, NOT NULL

nome: - Tipo: Texto. - Restrição: NOT NULL.

ano_nascimento: - Tipo: Numérico Inteiro. - Restrição: Positivo, pode aceitar nulos (NULL).

data_nascimento: - Tipo: Data. - Restrição: Formato padrão de data (YYYY-MM-DD). Pode aceitar nulos (NULL).

local_nascimento: - Tipo: Texto. - Restrição: Texto livre, pode aceitar nulos (NULL).

etnia: - Tipo: Texto. - Restrição: Pode aceitar nulos (NULL).

religiao: - Tipo: Texto. - Restrição: Pode aceitar nulos (NULL).

orient_sexual: - Tipo: Texto. - Restrição: Aceita nulos (NULL). Valores identificados como “Na” no sistema de origem devem ser convertidos e tratados formalmente como NULL no banco de dados.

FILME

id_filme (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

titulo: - Tipo: Texto.

CATEGORIA

id_categoria (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

nome: - Tipo: Texto. - Restrição: NOT NULL.

EDICAO

id_edicao (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

ano: - Tipo: Numérico Inteiro. - Restrição: O ano deve ser maior ou igual a 1927 (ano inicial da premiação no dataset).

PREMIO

id_premio (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

id_vencedor: - Tipo: Numérico Inteiro.

id_filme: - Tipo: Numérico Inteiro.

id_categoria: - Tipo: Numérico Inteiro.

id_edicao: - Tipo: Numérico Inteiro.

4. Etapa 2: Modelo Relacional

A modelagem Entidade-Relacionamento anterior permitiu uma abordagem bem direta para a modelagem Relacional, cada entidade se tornou 1 tabela relação, a entidade associativa formou uma tabela associativa da relação M:N, constituindo-se das chaves primárias de cada uma das outras relações como chaves estrangeiras.

```
vencedor(id_vencedor PK, nome, ano_nascimento, data_nascimento,  
         local_nascimento, etnia, religiao, orient_sexual)
```

```
filme(id_filme PK, titulo)
```

```
categoria(id_categoria PK, nome)
```

```
edicao(id_edicao PK, ano)
```

```
premio(id_premio PK,  
       id_vencedor FK → vencedor,  
       id_filme    FK → filme,  
       id_categoria FK → categoria,  
       id_edicao    FK → edicao)
```

Normalização

O processo de normalização para a base de dados escolhida se deu de maneira mais simples, por se tratar de uma base de dados com poucas colunas. As avaliações para cada forma normal para as tabelas modeladas anteriormente se da da seguinte maneira:

1FN: todos os valores são atômicos em todas as tabelas;

2FN: todas as tabelas têm chave primária simples, portanto dependências parciais são impossíveis;

3FN: o único caso observado foi `ano_nascimento` e `data_nascimento` na tabela `VENCEDOR`. Optou-se por manter ambos pois há 1 registro com `birth_year`, mas sem `birth_date`, mas adicionou-se a restrição de integridade `CHECK` para que o `ano_nascimento` seja o mesmo presente em `data_nascimento`. Não há dependências transitivas nas demais tabelas.

5. Etapa 3: Implementação Física

A definição das tabelas do esquema relacional (DDL) e a validação dos dados e foi feita em SQL (arquivos `Etapa3_SQL/01_ddl_criar_tabelas.sql` e `Etapa3_SQL/03_validacao_cargas.sql`, respectivamente).

Banco de dados

- **SGBD:** PostgreSQL 16 (via Docker)
- **Container:** `oscar-db`
- **Banco:** `oscar`

Restrições implementadas

Restrição	Tipo	Tabela
<code>id_*</code> únicos e não nulos	Chave primária	Todas
<code>nome NOT NULL</code>	Entidade	<code>vencedor</code> , <code>filme</code> , <code>categoria</code>
<code>ano >= 1927</code>	Domínio	<code>edicao</code>
<code>ano_nascimento = YEAR(data_nascimento)</code>	Consistência	<code>Vencedor</code>
FKs referenciam registros existentes	Referencial	<code>premio</code>
<code>(id_vencedor, id_categoria, id_edicao)</code> único	Negócio	<code>premio</code>

Índices criados

```
CREATE INDEX idx_premio_vencedor ON premio(id_vencedor);
CREATE INDEX idx_premio_filme ON premio(id_filme);
CREATE INDEX idx_premio_categoria ON premio(id_categoria);
CREATE INDEX idx_premio_edicao ON premio(id_edicao);
```

6. Etapa 3: Carga dos Dados

Pipeline em Python (`Etapa3_SQL/02_carga_dados.py`) usando `psycopg2`.

Ordem de inserção: 1. `edicao` — 87 cerimônias 2. `categoria` — 5 categorias 3. `filme` — 335 títulos únicos 4. `vencedor` — 348 pessoas únicas (deduplicadas por nome) 5. `premio` — 415 registros (um por linha do CSV)

Validação pós-carga: - Zero registros órfãos em todas as FKs - Nenhuma duplicata na restrição de negócio de `PREMIO`. - NULLs distribuídos como esperado (`religion`: 219, `orient_sexual`: 10)


7. Etapa 4: Análise Exploratória

Com o banco populado, formulamos perguntas que exploram padrões históricos de diversidade, prestígio e longevidade de carreira entre os vencedores do Oscar (1927–2014). As consultas completas estão no arquivo `Etapa4_EDA/05_consultas_sql.sql`.

P1 — Quais filmes venceram mais de uma categoria na mesma cerimônia?

A Figura “*Top 15 filmes com mais categorias vencidas na mesma edição*” revela que 13 filmes no total receberam 3 das 5 categorias do Oscar na mesma cerimônia, considerando a extensão temporal da base de dados. 60 filmes no total venceram 2 ou mais categorias, o mais recente sendo *Dallas Buyers Club* (2014). Os filmes da Figura estão organados pelo ano de premiação.


```
SELECT
  f.titulo,
  e.ano,
  COUNT(*)                                AS categorias_vencidas,
  STRING_AGG(c.nome, ' ' ORDER BY c.nome) AS quais_categorias
FROM premio p
JOIN filme   f ON f.id_filme   = p.id_filme
JOIN edicao   e ON e.id_edicao   = p.id_edicao
JOIN categoria c ON c.id_categoria = p.id_categoria
GROUP BY f.titulo, e.ano
HAVING COUNT(*) > 1
ORDER BY categorias_vencidas DESC, e.ano;
```



P2 — Como a proporção de vencedores não-brancos mudou ao longo das décadas?

Até os anos 1970, a proporção de vencedores não-brancos foi praticamente zero, atingindo no máximo cerca de 7% na década de 1950. A partir dos anos 2000, subiu para cerca de 19%, ainda longe de representar a diversidade da população americana. A Figura “*Diversidade étnica dos vencedores do Oscar por década*” mostra a variação da proporção entre brancos e não-brancos ao decorrer das décadas, o eixo esquerdo e as barras se referem aos valores absolutos, enquanto a linha vermelha e o eixo direito se referem ao valor percentual.

```
SELECT
    (e.ano / 10) * 10                                AS decada,
    COUNT(*)                                          AS total_premios,
    COUNT(*) FILTER (WHERE v.etnia <> 'White')        AS nao_brancos,
    ROUND(
        COUNT(*) FILTER (WHERE v.etnia <> 'White') * 100.0
        / COUNT(*), 1
    )                                                  AS pct_nao_brancos
FROM premio p
JOIN vencedor v ON v.id_vencedor = p.id_vencedor
JOIN edicao e ON e.id_edicao = p.id_edicao
GROUP BY decada
ORDER BY decada;
```



P3 — Qual a idade média dos vencedores por categoria? Quem ganhou mais jovem e mais velho?

Atrizes vencem mais jovens (média 37 anos), a mais jovem foi Tatum O’Neal com 11 anos (Paper Moon, 1974) e a mais velha foi Peggy Ashcroft (A Passage to India, 1985) com 78 anos. Entretanto, atores coadjuvantes vencem mais velhos (média 51), o mais velho foi Christopher Plummer com 83 anos (Beginning, 2012) e o mais jovem foi Timothy Hutton (Ordinary People, 1981) com 21 anos. A Figura “*Idade dos vencedores por categoria (média e amplitude)*” mostra um gráfico com barras indicando o valor médio das idades em cada categoria, enquanto as linhas verticais delimitam o mínimo e o máximo de cada uma, respectivamente.

```


SELECT
    c.nome
    ROUND(AVG(e.ano - v.ano_nascimento), 1)
    MIN(e.ano - v.ano_nascimento)
    MAX(e.ano - v.ano_nascimento)
AS categoria,
AS idade_media,
AS mais_jovem,
AS mais_velho
FROM premio p
JOIN vencedor v ON v.id_vencedor = p.id_vencedor
JOIN edicao e ON e.id_edicao = p.id_edicao
JOIN categoria c ON c.id_categoria = p.id_categoria
WHERE v.ano_nascimento IS NOT NULL
GROUP BY c.nome
ORDER BY idade_media;

```

```

(
    SELECT v.nome, c.nome AS categoria, e.ano,
        (e.ano - v.ano_nascimento) AS idade, 'mais jovem' AS tipo
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
    JOIN categoria c ON c.id_categoria = p.id_categoria
    WHERE v.ano_nascimento IS NOT NULL
    ORDER BY idade ASC
    LIMIT 5
)
UNION ALL
(
    SELECT v.nome, c.nome, e.ano,
        (e.ano - v.ano_nascimento), 'mais velho'
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
    JOIN categoria c ON c.id_categoria = p.id_categoria
    WHERE v.ano_nascimento IS NOT NULL
    ORDER BY (e.ano - v.ano_nascimento) DESC
    LIMIT 5
)
ORDER BY tipo, idade;


```



P4 — Entre quem ganhou mais de um Oscar, qual foi o maior intervalo de anos entre as vitórias?

Helen Hayes esperou 39 anos entre seu primeiro (1932) e segundo Oscar (1971), o maior intervalo registrado. Katharine Hepburn esperou 34 anos (1934–1968) e Meryl Streep esperou 29 anos (1983–2012). A Figura “*Top 10 maiores intervalos entre vitórias consecutivas*” mostra os 10 vencedores de Oscars com maiores intervalos entre premiações.

```
WITH vitorias_ordenadas AS (
    SELECT
        v.nome,
        e.ano,
        LAG(e.ano) OVER (PARTITION BY v.id_vencedor ORDER BY e.ano) AS ano_anterior
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
)
SELECT
    nome,
    ano_anterior AS primeiro_oscar,
    ano AS segundo_oscar,
    (ano - ano_anterior) AS intervalo_anos
FROM vitorias_ordenadas
WHERE ano_anterior IS NOT NULL
ORDER BY intervalo_anos DESC
LIMIT 10;
```




P5 — Em que ano cada categoria teve seu primeiro vencedor não-branco?

A primeira categoria a contemplar um não-branco foi a de Melhor Atriz Coadjuvante, com Hattie McDaniel (Gone with the Wind, 1940), uma atriz negra. Após isso, demorou 11 anos até que Jose Ferrer entrasse como primeiro vencedor não-branco da categoria Melhor Ator (Cyrano de Bergerac, 1951).

```
WITH ranking AS (
  SELECT
    c.nome,
    v.nome,
    v.etnia,
    e.ano,
    ROW_NUMBER() OVER (PARTITION BY c.id_categoria ORDER BY e.ano) AS rn
  FROM premio p
  JOIN vencedor v ON v.id_vencedor = p.id_vencedor
  JOIN edicao e ON e.id_edicao = p.id_edicao
  JOIN categoria c ON c.id_categoria = p.id_categoria
  WHERE v.etnia <> 'White'
)
SELECT categoria, vencedor, etnia, ano AS primeiro_ano_nao_branco
FROM ranking
WHERE rn = 1
ORDER BY primeiro_ano_nao_branco;
```

Categoria	Vencedor	Etnia	Ano
Best Supporting Actress	Hattie McDaniel	Black	1940
Best Actor	Jose Ferrer	Hispanic	1951
Best Supporting Actor	Anthony Quinn	Hispanic	1953
Best Actress	Halle Berry	Multiracial	2002
Best Director	Ang Lee	Asian	2006



8. Conclusão

O projeto permitiu implementar todas as etapas do ciclo de vida de um banco de dados relacional: modelagem ER com aplicação de conceitos como a entidade associativa, mapeamento relacional e verificação de normalidade até a terceira forma normal, implementação DDL com restrições de integridade, carga dos dados e análise exploratória via SQL, além da criação de visualizações utilizando *python*.

Os dados revelam que a Academia de Artes e Ciências Cinematográficas demorou décadas para reconhecer artistas não-brancos, com a primeira vitória não-branca em Melhor Diretor ocorrendo apenas em 2006 — quase 80 anos após a primeira cerimônia, mas que existe uma tendência de crescimento nas últimas décadas.