

Relatório — Projeto Final de Banco de Dados

Disciplina: Banco de Dados — DCC/UFMG

Professor: Pedro H. Barros

Dataset: Oscar AMPAS — Winner Demographics (1927–2014)

Grupo:

1. Lucas Samuel Fernandes Andrade Oliveira,
 2. Felipe Ribas Muniz,
 3. Iury Alves Bicalho e
 4. Bruno dos Santos Lopes
-

1. Introdução

Este projeto implementa o ciclo completo de um banco de dados relacional sobre os vencedores do Oscar (Academy Awards), premiação anual da Academia de Artes e Ciências Cinematográficas dos Estados Unidos (AMPAS). O dataset contém informações demográficas de vencedores de cinco categorias principais entre 1927 e 2014, permitindo análises sobre representatividade étnica, longevidade de carreira e domínio artístico ao longo de quase nove décadas de cinema.

As etapas de um projeto de banco de dados desenvolvidas partem do projeto conceitual Entidade-Relacionamento, que é depois convertido num modelo Relacional e testado sobre as premissas das 3 formas normais. Os modelos projetados são então implementados em SQL por meio da Data Definition language (DDL) e a base de dados resultante é populada com o arquivo csv. Antes de se executar as análises e consultas SQL, um tratamento é feito, seguido da análise exploratória dos dados.

Motivação

O Oscar é a premiação cinematográfica mais influente do mundo. Analisar o perfil dos vencedores ao longo do tempo revela padrões históricos de diversidade — ou ausência dela — na indústria do cinema.

2. Dataset

A base de dados utilizada, “World Oscar AMPAS winner demographics”, contém dados a respeito das categorias: Melhor Atriz, Melhor Ator, Melhor Diretor, Melhor Ator Coadjuvante, Melhor Atriz Coadjuvante, para as edições da premiação que ocorreram entre 1927 e 2014. Os atributos do dataset e a relação das variáveis presentes está mostrada na tabela a seguir:

Atributo	Valor
Fonte	FiveThirtyEight / AMPAS
Arquivo	world_ampas_oscar_winner_demographics.csv
Linhas	415
Colunas	10
Período	1927 a 2014

Colunas originais

Coluna	Tipo	Descrição
name	texto	Nome do vencedor
birth_year	inteiro	Ano de nascimento

Coluna	Tipo	Descrição
birth_date	data	Data de nascimento
birthplace	texto	Local de nascimento (texto livre)
race_ethnicity	texto	Etnia (6 valores: White, Black, Hispanic, Asian, Multiracial, Middle Eastern)
religion	texto	Religião — 62% ausente
sexual_orientation	texto	Orientação sexual — “Na” tratado como NULL
year_edition	inteiro	Ano da cerimônia
category	texto	Categoria do Oscar (5 categorias: Melhor Atriz, Melhor Ator, Melhor Diretor, Melhor Ator Coadjuvante, Melhor Atriz Coadjuvante)
movie	texto	Filme premiado

Tratamento de dados ausentes

Foram realizadas os seguintes tratamentos na base original importada:

- **religion:** 62% de ausência estrutural — dado não coletado para todos os vencedores históricos. Tratado como NULL.
- **sexual_orientation:** string "Na" convertida para NULL na carga.
- **birth_date:** 1 registro ausente; **birth_year** mantido para não perder informação.

3. Etapa 1: Modelo Entidade-Relacionamento

Entidades

Entidade	Atributos	Chave
VENCEDOR	nome, ano_nascimento, data_nascimento, local_nascimento, etnia, religiao, orient_sexual	id_vencedor
FILME	titulo	id_filme
CATEGORIA	nome	id_categoria
EDICAO	ano	id_edicao
PREMIO	id_vencedor, id_filme, id_categoria, id_edicao	id_premio


Relacionamentos

O projeto para o banco de dados considerou a criação de PREMIO, que é uma **entidade associativa** que conecta as quatro demais entidades. PREMIO permite que VENCEDOR, FILME, EDICAO e CATEGORIA se relacionem diretamente, de forma que caracterizem uma entrada na base de dados, ou seja, cada PREMIO corresponde a uma das categorias do Oscar em determinada edição, da qual houve um vencedor por causa de determinado filme.

Nessa estruturação, é obrigatório que cada uma dessas 4 entidades possuam uma respectiva entrada nas demais 3 que se associem a ela, caracterizando uma participação total. A entidade associativa caracteriza um relacionamento M:N.

Diagrama ER

O diagrama a seguir representa o esquemático da modelagem apresentada anteriormente, com as entidades, relacionamentos representados pela notação clássica.



Restrições de integridade de domínio

VENCEDOR

id_vencedor (Chave): - Tipo: Numérico Inteiro (ex: INT). - Restrição: Único, NOT NULL

nome: - Tipo: Texto. - Restrição: NOT NULL.

ano_nascimento: - Tipo: Numérico Inteiro. - Restrição: Positivo, pode aceitar nulos (NULL).

data_nascimento: - Tipo: Data. - Restrição: Formato padrão de data (YYYY-MM-DD). Pode aceitar nulos (NULL).

local_nascimento: - Tipo: Texto. - Restrição: Texto livre, pode aceitar nulos (NULL).

etnia: - Tipo: Texto. - Restrição: Pode aceitar nulos (NULL).

religiao: - Tipo: Texto. - Restrição: Pode aceitar nulos (NULL).

orient_sexual: - Tipo: Texto. - Restrição: Aceita nulos (NULL). Valores identificados como “Na” no sistema de origem devem ser convertidos e tratados formalmente como NULL no banco de dados.

FILME

id_filme (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

titulo: - Tipo: Texto.

CATEGORIA

id_categoria (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

nome: - Tipo: Texto. - Restrição: NOT NULL.

EDICAO

id_edicao (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

ano: - Tipo: Numérico Inteiro. - Restrição: O ano deve ser maior ou igual a 1927 (ano inicial da premiação no dataset).

PREMIO

id_premio (Chave): - Tipo: Numérico Inteiro. - Restrição: Único, NOT NULL.

id_vencedor: - Tipo: Numérico Inteiro.

id_filme: - Tipo: Numérico Inteiro.

id_categoria: - Tipo: Numérico Inteiro.

id_edicao: - Tipo: Numérico Inteiro.

4. Etapa 2: Modelo Relacional

A modelagem Entidade-Relacionamento anterior permitiu uma abordagem bem direta para a modelagem Relacional, cada entidade se tornou 1 tabela relação, a entidade associativa formou uma tabela associativa da relação M:N, constituindo-se das chaves primárias de cada uma das outras relações como chaves estrangeiras.

```
vencedor(id_vencedor PK, nome, ano_nascimento, data_nascimento,  
         local_nascimento, etnia, religiao, orient_sexual)
```

```
filme(id_filme PK, titulo)
```

```
categoria(id_categoria PK, nome)
```

```
edicao(id_edicao PK, ano)
```

```
premio(id_premio PK,  
       id_vencedor FK → vencedor,  
       id_filme    FK → filme,  
       id_categoria FK → categoria,  
       id_edicao    FK → edicao)
```

Normalização

1FN: todos os valores são atômicos. `local_nascimento` é texto livre, mas atômico por linha.

2FN: todas as tabelas têm chave primária simples — dependências parciais são impossíveis.

3FN: único caso analisado foi `ano_nascimento` vs `data_nascimento` em `VENCEDOR`. Optou-se por manter ambos pois há 1 registro com `birth_year` mas sem `birth_date` completa — eliminar a coluna causaria perda real de informação. Não há dependências transitivas nas demais tabelas.

5. Etapa 3: Implementação Física

A definição das tabelas do esquema relacional (DDL) e a validação dos dados e foi feita em SQL (arquivos `Etapa3_SQL/01_ddl_criar_tabelas.sql` e `Etapa3_SQL/03_validacao_cargas.sql`, respectivamente).

Banco de dados

- **SGBD:** PostgreSQL 16 (via Docker)
- **Container:** `oscar-db`
- **Banco:** `oscar`

Restrições implementadas

Restrição	Tipo	Tabela
id_* únicos e não nulos	Chave primária	Todas
nome NOT NULL	Entidade	vencedor, filme, categoria
ano >= 1927	Domínio	edicao
FKs referenciam registros existentes	Referencial	premio
(id_vencedor, id_categoria, id_edicao) único	Negócio	premio

Índices criados

```
CREATE INDEX idx_premio_vencedor ON premio(id_vencedor);
CREATE INDEX idx_premio_filme ON premio(id_filme);
CREATE INDEX idx_premio_categoria ON premio(id_categoria);
CREATE INDEX idx_premio_edicao ON premio(id_edicao);
```

6. Etapa 3: Carga dos Dados

Pipeline em Python (Etapa3_SQL/02_carga_dados.py) usando psycopg2.

Ordem de inserção: 1. edicao — 87 cerimônias 2. categoria — 5 categorias 3. filme — 335 títulos únicos 4. vencedor — 348 pessoas únicas (deduplicadas por nome) 5. premio — 415 registros (um por linha do CSV)

Validação pós-carga: - Zero registros órfãos em todas as FKs - Nenhuma duplicata na restrição de negócio de PREMIO. - NULLs distribuídos como esperado (religion: 219, orient_sexual: 10)


7. Etapa 4: Análise Exploratória

Com o banco populado, formulamos perguntas que exploram padrões históricos de diversidade, prestígio e longevidade de carreira entre os vencedores do Oscar (1927–2014). As consultas completas estão no arquivo Etapa4_EDA/05_consultas_sql.sql.

P1 — Quais filmes venceram mais de uma categoria na mesma cerimônia?

It Happened One Night (1935), *Gone with the Wind* (1940) e *Going My Way* (1945) foram os únicos a vencer 3 categorias em uma mesma cerimônia. 60 filmes no total venceram 2 ou mais categorias.


```
SELECT
  f.titulo,
  e.ano,
  COUNT(*) AS categorias_vencidas,
  STRING_AGG(c.nome, ', ' ORDER BY c.nome) AS quais_categorias
FROM premio p
JOIN filme f ON f.id_filme = p.id_filme
JOIN edicao e ON e.id_edicao = p.id_edicao
JOIN categoria c ON c.id_categoria = p.id_categoria
GROUP BY f.titulo, e.ano
HAVING COUNT(*) > 1
ORDER BY categorias_vencidas DESC, e.ano;
```



P2 — Como a proporção de vencedores não-brancos mudou ao longo das décadas?

Até os anos 1970, a proporção de vencedores não-brancos foi praticamente zero. A partir dos anos 2000, subiu para cerca de 19%, ainda longe de representar a diversidade da população americana.

```
SELECT
    (e.ano / 10) * 10                                AS decada,
    COUNT(*)                                          AS total_premios,
    COUNT(*) FILTER (WHERE v.etnia <> 'White')       AS nao_brancos,
    ROUND(
        COUNT(*) FILTER (WHERE v.etnia <> 'White') * 100.0
        / COUNT(*), 1
    )                                                 AS pct_nao_brancos
FROM premio p
JOIN vencedor v ON v.id_vencedor = p.id_vencedor
JOIN edicao e ON e.id_edicao = p.id_edicao
GROUP BY decada
ORDER BY decada;
```



P3 — Qual a idade média dos vencedores por categoria? Quem ganhou mais jovem e mais velho?

Atrizes vencem mais jovens (média 37 anos) enquanto atores coadjuvantes vencem mais velhos (média 51). A mais jovem foi Tatum O'Neal com 11 anos (1974); o mais velho foi Christopher Plummer com 83 anos (2012).


```
SELECT
    c.nome
    ROUND(AVG(e.ano - v.ano_nascimento), 1)
    MIN(e.ano - v.ano_nascimento)
    MAX(e.ano - v.ano_nascimento)
AS categoria,
AS idade_media,
AS mais_jovem,
AS mais_velho
FROM premio p
JOIN vencedor v ON v.id_vencedor = p.id_vencedor
JOIN edicao e ON e.id_edicao = p.id_edicao
JOIN categoria c ON c.id_categoria = p.id_categoria
WHERE v.ano_nascimento IS NOT NULL
GROUP BY c.nome
ORDER BY idade_media;
```

```
(
    SELECT v.nome, c.nome AS categoria, e.ano,
        (e.ano - v.ano_nascimento) AS idade, 'mais jovem' AS tipo
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
    JOIN categoria c ON c.id_categoria = p.id_categoria
    WHERE v.ano_nascimento IS NOT NULL
    ORDER BY idade ASC
    LIMIT 5
)
UNION ALL
(
    SELECT v.nome, c.nome, e.ano,
```

```

        (e.ano - v.ano_nascimento), 'mais velho'
FROM premio p
JOIN vencedor v ON v.id_vencedor = p.id_vencedor
JOIN edicao e ON e.id_edicao = p.id_edicao
JOIN categoria c ON c.id_categoria = p.id_categoria
WHERE v.ano_nascimento IS NOT NULL
ORDER BY (e.ano - v.ano_nascimento) DESC
LIMIT 5
)
ORDER BY tipo, idade;

```



P4 — Entre quem ganhou mais de um Oscar, qual foi o maior intervalo de anos entre as vitórias?

Helen Hayes esperou 39 anos entre seu primeiro (1932) e segundo Oscar (1971), o maior intervalo registrado. Katharine Hepburn também esperou 34 anos (1934–1968).


```

WITH vitorias_ordenadas AS (
    SELECT
        v.nome,
        e.ano,
        LAG(e.ano) OVER (PARTITION BY v.id_vencedor ORDER BY e.ano) AS ano_anterior
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
)
SELECT
    nome,
    ano_anterior AS primeiro_oscar,
    ano AS segundo_oscar,
    (ano - ano_anterior) AS intervalo_anos
FROM vitorias_ordenadas

```




```
WHERE ano_anterior IS NOT NULL
ORDER BY intervalo_anos DESC
LIMIT 10;
```



P5 — Em que ano cada categoria teve seu primeiro vencedor não-branco?

```
WITH ranking AS (
    SELECT
        c.nome AS categoria,
        v.nome AS vencedor,
        v.etnia,
        e.ano,
        ROW_NUMBER() OVER (PARTITION BY c.id_categoria ORDER BY e.ano) AS rn
    FROM premio p
    JOIN vencedor v ON v.id_vencedor = p.id_vencedor
    JOIN edicao e ON e.id_edicao = p.id_edicao
    JOIN categoria c ON c.id_categoria = p.id_categoria
    WHERE v.etnia <> 'White'
)
SELECT categoria, vencedor, etnia, ano AS primeiro_ano_nao_branco
FROM ranking
WHERE rn = 1
ORDER BY primeiro_ano_nao_branco;
```

Categoria	Vencedor	Etnia	Ano
Best Supporting Actress	Hattie McDaniel	Black	1940
Best Actor	Jose Ferrer	Hispanic	1951
Best Supporting Actor	Anthony Quinn	Hispanic	1953
Best Actress	Halle Berry	Multiracial	2002
Best Director	Ang Lee	Asian	2006



8. Conclusão

O projeto implementou com sucesso todas as etapas do ciclo de vida de um banco de dados relacional: modelagem ER, mapeamento relacional, normalização até 3FN, implementação DDL com restrições de integridade, pipeline de carga e análise exploratória via SQL e visualizações.

Os dados revelam que a Academia de Artes e Ciências Cinematográficas demorou décadas para reconhecer artistas não-brancos, com a primeira vitória não-branca em Best Director ocorrendo apenas em 2006 — quase 80 anos após a primeira cerimônia.