

Trabalho Prático

Do Mundo Real ao Insight:

Modelagem, Implementação e Análise de uma Base de Dados Aberta

Projeto integrador: Modelo ER → Modelo Relacional → SQL → Análise Exploratória de Dados

Informações Gerais

Modalidade: grupos de 3 a 4 integrantes

Dataset: livre escolha, qualquer base de dados aberta (governamental ou não)

Entregáveis: relatório técnico, código (notebook/scripts) e apresentação oral

Disciplina: Banco de Dados (Prof. Pedro H. Barros, DCC/UFMG)

Política de uso de Inteligência Artificial

O uso de ferramentas de IA generativa (ChatGPT, Copilot, Gemini, Claude, etc.) é **proibido** na elaboração do **código** e do **relatório técnico**. Esses dois artefatos devem refletir exclusivamente o trabalho e a compreensão do grupo.

O uso de IA é **permitido** apenas como apoio à construção dos **slides** da apresentação (ex.: revisão de texto, sugestões de layout), desde que **declarado** na última página dos slides com a ferramenta utilizada e a forma de uso.

1. Apresentação e Objetivos

Este Trabalho Prático (TP) propõe um **projeto integrador** que percorre, do início ao fim, o ciclo de vida de uma base de dados: da concepção conceitual à extração de conhecimento. Cada grupo escolherá uma **base de dados aberta** de seu interesse e, sobre ela, exercitará de forma prática os principais conteúdos vistos ao longo da disciplina, desde o **modelo Entidade-Relacionamento** até a **análise exploratória com SQL**.

A ideia central é que dados abertos só geram valor para a sociedade quando alguém é capaz de **modelá-los, integrá-los, consultá-los e interpretá-los**. Este é exatamente o papel do profissional de Banco de Dados.

Objetivos de Aprendizagem

- Projetar um modelo conceitual (ER/EER) para um domínio real, com restrições de integridade.
- Mapear o modelo conceitual para o modelo relacional e normalizá-lo.
- Implementar o esquema em SQL (DDL) e povoá-lo a partir de uma fonte de dados aberta.
- Formular consultas SQL progressivas (DML) para responder perguntas investigativas.
- Realizar análise exploratória de dados (EDA) e comunicar os achados de forma crítica.

2. Escolha do Dataset

A escolha do conjunto de dados é **livre**. O grupo pode usar a base CPGF (Cartão de Pagamento do Governo Federal) vista em aula, escolher outra base de dados aberta brasileira, ou qualquer outra fonte de dados pública de seu interesse (esportes, clima, saúde, transporte, cultura, etc.).

Critérios mínimos para o dataset

1. Deve ser de acesso público e legal (sem dados sensíveis ou protegidos).
2. Deve ter volume razoável, sugestão: ao menos alguns milhares de registros.
3. Deve possuir riqueza estrutural suficiente para justificar pelo menos **4 entidades relacionadas** no modelo ER.
4. Deve permitir formular perguntas analíticas interessantes (não apenas uma tabela trivial).

Sugestões de fontes de dados abertos

Fonte	Tipo de dados	Onde acessar
Portal da Transparência	Gastos, repasses, sanções	portaldatransparencia.gov.br
dados.gov.br	Catálogo geral de dados abertos	dados.gov.br
Base dos Dados	Diversos datasets já em SQL	basedosdados.org
INEP	Censo Escolar, ENEM, IDEB	inep.gov.br
DATASUS	Saúde pública	datasus.gov.br
IBGE / outros	Demografia, economia e mais	ibge.gov.br

3. Etapas do Trabalho

O TP está organizado em quatro etapas sequenciais que reproduzem o ciclo completo de um projeto de banco de dados. Cada etapa constrói sobre a anterior.

3.1 (Etapa 1) Projeto Conceitual (Modelo ER/EER)

A partir do domínio escolhido, o grupo deve projetar um modelo conceitual que represente a realidade dos dados.

- Identificar entidades, atributos (incluindo chaves) e relacionamentos.
- Especificar cardinalidades e restrições de participação.
- Aplicar conceitos de EER quando fizer sentido: especialização/generalização, agregação.
- Documentar as **restrições de integridade** do domínio (ex.: um valor não pode ser negativo, uma data deve ser válida).
- Apresentar o diagrama em notação consistente (ER clássica ou UML, declarar qual).

Entregável da Etapa 1

Diagrama ER/EER + texto descrevendo as decisões de modelagem e as restrições de integridade identificadas.

3.2 (Etapa 2) Modelo Relacional e Normalização

Converter o modelo conceitual em um esquema relacional implementável.

- Aplicar o **mapeamento ER → Relacional** (regras de tradução de entidades, relacionamentos e atributos).
- Definir chaves primárias e estrangeiras, e demais restrições.
- Analisar as dependências funcionais e **normalizar** o esquema (justificar até qual forma normal (pelo menos 3FN) e por quê).
- Discutir eventuais decisões de desnormalização, se houver, e seu motivo.

Entregável da Etapa 2

Esquema relacional (lista de relações com chaves) + análise de normalização justificada.

3.3 (Etapa 3) Implementação em SQL (DDL + Carga)

Materializar o esquema e carregar os dados reais.

- Escrever os comandos **DDL** (`CREATE TABLE`) com tipos, chaves e restrições, usando DuckDB, SQLite, PostgreSQL ou equivalente.
- Carregar os dados a partir do arquivo bruto (CSV/Parquet/JSON), ex.: `read_csv_auto` no DuckDB.
- Realizar o **tratamento/limpeza** necessário: tipos, valores ausentes, inconsistências, duplicatas.
- Documentar quantos registros foram carregados e quaisquer linhas descartadas (com justificativa).

Entregável da Etapa 3

Scripts DDL + código de carga/limpeza reproduzível + relatório do processo (quantidade de registros, problemas encontrados).

3.4 (Etapa 4) Consultas e Análise Exploratória (SQL + EDA)

Usar SQL para responder perguntas e extrair insights do domínio. O grupo deve formular suas próprias perguntas investigativas e respondê-las com consultas progressivas.

Requisitos mínimos de consultas SQL

- **SELECT** com **WHERE** (filtragem e projeção).
- Agregações: **COUNT**, **SUM**, **AVG**, **MIN**, **MAX**, incluindo **COUNT(DISTINCT ...)**.
- **GROUP BY** e **HAVING** para agrupar e filtrar grupos.
- Pelo menos uma consulta com **JOIN** entre tabelas (aproveitando o modelo relacional projetado).
- Pelo menos uma consulta mais avançada à escolha do grupo (subconsulta, **CTE** ou *window function*).

Análise exploratória (EDA)

- Formular de 3 a 5 perguntas investigativas sobre o domínio.
- Responder cada uma com SQL e ao menos uma visualização (gráfico).
- Discutir criticamente os achados: há padrões? anomalias? dados ausentes? O que isso significa no mundo real?

Entregável da Etapa 4

Conjunto de consultas SQL comentadas, visualizações e a discussão crítica dos resultados.

4. Entregáveis

Cada grupo deve submeter três artefatos:

4.1 Relatório Técnico (PDF)

Documento que conta a história do projeto, contendo:

- Identificação do grupo e do dataset escolhido (com fonte e link).
- Uma seção para cada uma das quatro etapas, com os respectivos entregáveis.
- Diagramas (ER e esquema relacional) legíveis e bem apresentados.
- As consultas SQL, seus resultados e a discussão crítica dos achados.
- Conclusão: o que o grupo aprendeu e quais limitações encontrou.

Restrição de IA — Relatório

O relatório técnico deve ser integralmente redigido pelo grupo. O uso de ferramentas de IA generativa para gerar é **proibido**. Pode utilizar como auxílio para reformular **pequenos** trechos do texto.

4.2 Código (Notebook ou Repositório)

- Notebook (Jupyter/Colab) ou scripts reproduzíveis, bem comentados.
- Deve permitir reproduzir todo o pipeline: `dados` → `carga` → `DDL` → `consultas` → `gráficos`.
- Incluir instruções de execução (README) e lista de dependências.

Restrição de IA — Código

O código deve ser escrito pelo grupo sem auxílio de ferramentas de autocompletar com IA (GitHub Copilot, ChatGPT, Gemini, etc.). O objetivo é que cada linha reflita o domínio real da linguagem SQL e de Python adquirido na disciplina. O grupo deve ser capaz de explicar qualquer trecho do código durante a apresentação.

4.3 Apresentação Oral

- Apresentação de **10 a 15 minutos** por grupo (slides).
- Todos os integrantes devem participar.
- Foco em: domínio escolhido, modelo, e **principalmente** os insights encontrados.
- Reservar tempo para perguntas.

- Uso de IA nos slides é **permitido**, desde que declarado na última página (ferramenta utilizada e forma de uso).

5. Critérios de Avaliação

A nota será composta pelos seguintes critérios (total: **25 pontos**):

Critério	O que se avalia	Pts
Modelo conceitual (ER/EER)	Corretude, cardinalidades, restrições de integridade	3
Modelo relacional e normalização	Mapeamento correto, chaves, normalização justificada	3
Implementação SQL e carga	DDL correto, carga e limpeza de dados reproduzíveis	3
Consultas e EDA	Variedade e corretude das consultas, qualidade dos insights	4
Relatório e código	Clareza, organização, reprodutibilidade, documentação	4
Apresentação	Comunicação, domínio do conteúdo, participação do grupo	8
Total		25

Bônus (até +3 pontos)

- Conexão explícita com a LAI / contexto de transparência e cidadania de dados.
- Uso de técnicas além do escopo: detecção de anomalias, dashboard interativo, integração de múltiplas fontes.
- Profundidade analítica que vá além do mínimo exigido.

6. Orientações Finais

- Grupos de **3 a 4 integrantes**; a formação deve ser registrada no Checkpoint 0 (no Moodle).
- A escolha do dataset deve ser aprovada pelo professor antes do início do desenvolvimento.
- Trabalhos com indícios de plágio ou uso não declarado de código de terceiros serão penalizados; é permitido usar bibliotecas e citar fontes.
- **Política de IA:** o uso de IA generativa é proibido no código e no relatório; permitido apenas nos slides, com declaração obrigatória. Ver Seção 4 para detalhes.
- Dúvidas devem ser encaminhadas nos canais da disciplina ou nos horários de atendimento.

*Bom trabalho! Lembrem-se: a **LAI** garante que os dados existam e sejam públicos;
cabe a vocês transformá-los em conhecimento.*